

Diffusion Exponential Integral Sampler (DEIS) 이시.

→ ODE를 이산화하고, error를 줄이기 위해 semilinear structure 이용

## 1. Introduction.

Diffusion은 기본적으로 diffusion과 reverse로 이뤄짐.

→ Time-dependency score function을 배우기 때문에 score-based model 이라고 불림!

→ 다른 model보다 scalability가 좋고, hyperparam이 덜 민감

→ 모든 task에서 좋은 performance

하지만 노이즈 때문에 빠르게 하기 위한 방법들 연구.

→ 효율적인 reverse를 위한 forward 누적 및 변형 (DDIM)

→ numerical solver or SDE (Score-SDE, ...)

→ 등가: PNDM

DDIM은 Score-SDE의 PF의 이산화인데 Euler 같은 일반적인 방법보다 왜 성능이 좋을까?

따라서 빠른 sampling을 위해 DM의 reverse의 일반화되어 있는 이산화 방법 설립

Network 과잉이 가장 큰 resource를 필요로 한다.

∴ DM과 관련된 ODE/SDE와 fitting error와 이산화 error에 대해 조사.

같은 DM 이므로 이산화 방법이 따라 error가 극심히 다름

→ 오류를 조사하고 semilinear structure를 이용한 Exponential Integral (EI)가

가장 작은 error를 보인다는 것으로 보임

이산화 미러를 더 줄이기 위해 ODE의 비선형성을 근사하기 위한 교차 다항식이나

변형된 ODE에 Runge-kutta를 적용한다.

→ DEIS

## Contributions :

1. 빠른 sampling을 위한 marginal ODEs/SDEs 계열의 조사와 이에 대한 numerical solver에 대한 여러 조사.
2. DM이 일반적으로 적용할 수 있는 계한된 NFE에서 뛰어난 sampling quality를 보이는 DEIS 제안
3. DDIM의 아산타를 정당화하고, DDIM이 DEIS의 한 종류라는 것을 증명
4. DEIS의 성능 실험

## 2. Background.

- Forward noise diffusion.

$$\text{SDE: } dx = \underbrace{F_t x dt}_{\text{linear drift}} + \underbrace{G_t dw}_{\text{Diffusion}}, \quad (1)$$

Table 1: Two popular SDEs, variance preserving SDE (VPSDE) and variance exploding SDE (VESDE). The parameter  $\alpha_t$  is decreasing with  $\alpha_0 \approx 1, \alpha_T \approx 0$ , while  $\sigma_t$  is increasing.

SDE	$F_t$	$G_t$	$\mu_t$	$\Sigma_t$
VPSDE (Ho et al., 2020)	$\frac{1}{2} \frac{d \log \alpha_t}{dt} I$	$\sqrt{-\frac{d \log \alpha_t}{dt}} I$	$\sqrt{\alpha_t} I$	$(1 - \alpha_t) I$
VESDE (Song et al., 2020b)	0	$\sqrt{\frac{d[\sigma_t^2]}{dt}} I$	$I$	$\sigma_t^2 I$

- Backward denoising diffusion

Reverse-time diffusion process

$$dx = [F_t x dt - G_t G_t^T \nabla \log p_t(x)] dt + G_t dw, \quad (2)$$

- Training

$$\mathcal{L}(\theta) = \mathbb{E}_{t \sim \text{Unif}[0, T]} \mathbb{E}_{p(x_0) p_{0t}(x_t | x_0)} [\|\nabla \log p_{0t}(x_t | x_0) - s_\theta(x_t, t)\|_{\Lambda_t}^2]. \quad (3)$$



### 3. Fast Sampling with Learned Score Models

학습된  $S_\theta(x) \approx \nabla \log p_t(x)$ 가 훈련되면 infinity step으로 backward 가능

$\lambda \geq 0$  일 때, SDE 쿼를 고려하면 (일반화)

$$d\hat{x} = [F_t \hat{x} - \frac{1 + \lambda^2}{2} G_t G_t^T s_\theta(\hat{x}, t)] dt + \lambda G_t dw, \quad (4)$$

→  $\lambda=0$  이면 Score-SDE의 probability flow ODE

→  $\lambda=1$  이면, eq.2.

**Proposition 1.** When  $s_\theta(x, t) = \nabla \log p_t(x)$  for all  $x, t$ , and  $\hat{p}_T^* = \pi$ , the marginal distribution  $\hat{p}_t^*$  of Eq. (4) matches  $p_t$  of the forward diffusion Eq. (1) for all  $0 \leq t \leq T$ .

Fitting Error:  $S_\theta$  와  $\nabla \log p_t(x)$ 의 차이

Discretization Error: Eq.4의 이산화 Error

∴  $\lambda=0$ 을 중심으로 두 error를 해별하기 위해 연구.

VPSDE(DDPM)을 기준으로 함

#### 3.1 Can We Learn Globally Accurate Score?

Diffusion의 성공으로 인해 fitting Error가 작다고 생각하지만 실제로 크다.




Figure 2: Fitting error on a toy demo. Lighter areas represent higher probability region (left) and larger fitting error (right).

→  $p_t(x)$ 의 region이 작으면 error↑, 크면 error↓

즉, 낮은  $p_k$ 에 값 (낮은 확률) 이서는 높은 score가 보장됨

$\therefore$  이미지 같은 고차원 data는 작은 manifold에 모여있다

$\therefore \hat{x}_t$ 의 품질은 높아지면 모든  $t$ 에서  $p_k(x)$ 가 높아야 한다.

→ 큰 step을 취하는 것이 힘들

→ 좋은 이산화는 fitting error를 줄일수 있어야 함

### 3.1 Discretization Error

PF ODE( $\lambda=0$ )

$$\frac{d\hat{x}}{dt} = F_t \hat{x} - \frac{1}{2} G_t G_t^T s_\theta(\hat{x}, t). \quad (5)$$

이러한 정확한 solution은

$$\hat{x}_t = \Psi(t, s) \hat{x}_s + \int_s^t \Psi(t, \tau) \left[ -\frac{1}{2} G_\tau G_\tau^T s_\theta(\hat{x}_\tau, \tau) \right] d\tau, \quad (6)$$

↳  $\Psi(t, s)$ 는  $\frac{\partial}{\partial t} \Psi(t, s) = F_t \Psi(t, s)$ 를 만족함.

$\Psi(s, s) = I$ 가 time  $s \rightarrow t$ 까지의 transition matrix로 알려져 있을 때,

Eq.5가 linear term  $F_t \hat{x}$ 와 nonlinear term  $S_\theta(\hat{x}, t)$ 로 구성된 semilinear stiff ODE 다.

Eq.6를 근사하기 위해 다양한 이산화 scheme과 관련된 eq.5에 대한 다양한 numerical solver가 있다.

이산화 step size가 0으로 가면, 모든 solution이 eq.5로 수렴

특히, 큰 step size를 위해 eq.5의 discretization error 조사.

그리고 작은  $\lambda$ 의 Neural Function Evaluation (NFE)가 필요한 algorithm 개발

Ingredient 1. Exponential Integral over Euler method.