

기존 GAN의 경우 D는 T.F의 대한 확률 model이다.

확률 model은 0.1만 내뱉는다.

D를 energy function으로 사용하여 다른 각도로 보기 참.

G는 minimum E로 contrastive sample를 생성하려하니, D는 생성된 sample의 E가 크도록 학습됨!

* Introduction.

Energy-based model의 필수 요소는 input space에서 scalar로 mapping 되는 energy function이다.

훈련은 data로부터 맞는 것은 low energy로, 틀린 것은 high energy로 하는 energy surface를 구성하는 과정.

Supervised에서는 (X, Y) pair가 맞으면 $E \downarrow$, 틀리면 $E \uparrow$.

Unsupervised에서는 data manifold에서 낮은 E

Contrastive sample은 E로 높은 data point 나 낮은 data density 영역도 의미.

EBGAN에서는 D를 energy function으로 본다.

Energy function (이하 D)는 G에 대한 cost function으로 볼 수 있다.

↳ data 밀도가 높은 곳이 낮은 값, 낮은 곳이 높은 값

G는 낮은 E 영역에서 sample를 생성하는 trainable parameterized function.

D는 AEC, energy는 reconstruction error.

* The EBGAN MODEL

P_z 에서 P_{data} 의 따른 분포를 갖는 sample을 생성하고,

D 는 생성된 이미지, real image를 받고, $E \in \mathbb{R}$ 이 해당하는 energy를 출력

Objective function.

D 는 E 이 때에 objective function을 거쳐, 실제와 낮은 트로, 생성한 높은 트로 할당.

$$\begin{aligned}\mathcal{L}_D(x, z) &= D(x) + [m - D(G(z))]^+ \\ \mathcal{L}_G(z) &= D(G(z))\end{aligned}$$

m 은 positive margin 이고, $[\cdot]^+$ 는 $\max(0, \cdot)$ 을 의미.

$\mathcal{L}_D, \mathcal{L}_G$ 를 maximize

Optimality of the Solution.

P_x 는 G 로 생성된 image의 data distribution.

$$V(G, D) = \int_{x, z} \mathcal{L}_D(x, z) p_{data}(x) p_z(z) dx dz$$

$$U(G, D) = \int_z \mathcal{L}_G(z) p_z(z) dz$$

일 때, Nash equilibrium을 만족하는 (G^*, D^*) 이 존재.

$$V(G^*, D^*) \leq V(G, D) \quad \forall D$$

$$U(G^*, D^*) \leq U(G, D^*) \quad \forall G$$

Theorem 1. (D^*, G^*) 가 Nash equilibrium이 존재할 때, 거의 항상 $P_{G^*} = P_{data}$ 이고, $V(D^*, G^*) = m$ 이다.

Theorem 2. Nash equilibrium은 존재하고, i) $P_{G^*} = P_{data}$, ii) $D^*(x) = \gamma$ 일 $\gamma \in [0, m]$ 이 존재한다.

$$U(G^*, D^*) - U(G_0, D^*) = \int_x (p_{data} - p_{G_0}) D^*(x) dx \quad (21)$$

$$= \int_x (p_{data} - p_{G_0}) (D^*(x) - C) dx \quad (22)$$

$$= \int_S (p_{data} - p_{G_0}) (D^*(x) - C) dx + \int_{\mathbb{R}^N \setminus S} (p_{data} - p_{G_0}) (D^*(x) - C) dx \quad (23)$$

$$> 0 \quad (24)$$

Using Autoencoder.

D는 AE로 구성된다.

$$D(x) = \| \text{Dec}(\text{Enc}(x)) - x \|$$

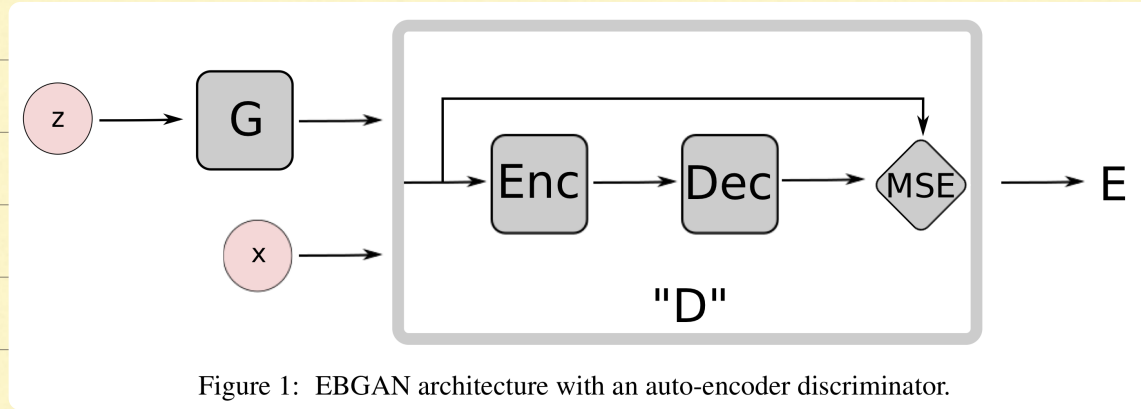



Figure 1: EBGAN architecture with an auto-encoder discriminator.

0과 1의 D보단 recon-based의 경우 D에 다양한 target을 제공

Binary의 경우 target이 2x이므로, minibatch에 맞춰서,

서로 다른 sample의 gradient가 orthogonal이 되게 한다.

나 두 sample의 기울기가 와 같이 서로 상충될 수 있다.

반면 recon-based의 경우 여러 방향의 기울기를 생성하여 효율성 있는 더 큰 minibatch를 허용한다.

그리고 AE는 energy-based이 아니므로, supervision이 negative sample 없이 manifold 학습이 가능하다.

나 D가 자체적으로 data manifold를 발견할 수 있다.

나 D와 G의 균형에서 더 자유로움

Connection to the regularized AE

한가지 문제는 AE가 identity function만 학습할 수도 있다

↳ data manifold 밖이 더 높은 energy를 push out함

↳ latent space regularization.

↳ recon이 제약을 걸며, input이 더 낮은 부분이 낮은 E

D가 contrastive sample은 생성하여 regularization.

↳ 유연성

↳ G의 다양한 표현

↳ sample 생성과, E function 학습의 직접적인 상호작용

Repelling regularizer

repelling regularizer는 P_{data} 의 하나 또는 몇으로 연결된 생성된 sample로부터 model은 유지하기 위한 목적으로

EBGAN의 AutoEncoder 이 쓰인다.

Minibatch D는 같은 의도로 개발됨

repelling regularizer는 representation level에서 수행되는 Pulling-away Term(PT)이다

$S \in \mathbb{R}^{s \times N}$ 를 Encoder의 output이나 batch의 sample representation이라고 하면,

$$f_{PT}(S) = \frac{1}{N(N-1)} \sum_i \sum_{j \neq i} \left(\frac{S_i^T S_j}{\|S_i\| \|S_j\|} \right)^2.$$

↳ sample들을 직교화하려고 함.

↳ cosine similarity는 below boundary에 invariant scale

↳ G에만 적용됨.

* Experiment.

semi-supervised 때는 m 을 점점 높여나간다.

P_G 가 data manifold에 가까워지면, D로부터의 loss가 줄어들도록

$P_G = P_{data}$ 일때, $m=0$ 으로.

m 은 너무 크면 불일치, 작으면 mode drop

↳ Appendix D




Figure 9: Generation from the EBGAN auto-encoder model trained with different m settings. From top to bottom, m is set to 1, 2, 4, 6, 8, 12, 16, 32 respectively. The rest setting is nLayerG=5, nLayerD=2, sizeG=1600, sizeD=1024, dropoutD=0, optimD=ADAM, optimG=ADAM, lr=0.001.

Contrastive sample은 reg이 높고있고, classifier의 output 더 많은 sample

» Appendix

A.

Lemma 1. Let $a, b \geq 0$, $\varphi(y) = ay + b[m - y]^+$. The minimum of φ on $[0, +\infty)$ exists and is reached in m if $a < b$, and it is reached in 0 otherwise (the minimum may not be unique).

Proof. The function φ is defined on $[0, +\infty)$, its derivative is defined on $[0, +\infty) \setminus \{m\}$ and $\varphi'(y) = a - b$ if $y \in [0, m)$ and $\varphi'(y) = a$ if $y \in (m, +\infty)$.

So when $a < b$, the function is decreasing on $[0, m)$ and increasing on $(m, +\infty)$. Since it is continuous, it has a minimum in m . It may not be unique if $a = 0$ or $a - b = 0$.

On the other hand, if $a \geq b$ the function φ is increasing on $[0, +\infty)$, so 0 is a minimum. \square

Lemma 2. If p and q are probability densities, then $\int_x \mathbb{1}_{p(x) < q(x)} dx = 0$ if and only if $\int_x \mathbb{1}_{p(x) \neq q(x)} dx = 0$.

Proof. Let's assume that $\int_x \mathbb{1}_{p(x) < q(x)} dx = 0$. Then

$$\int_x \mathbb{1}_{p(x) > q(x)} (p(x) - q(x)) dx \quad (15)$$

$$= \int_x (1 - \mathbb{1}_{p(x) \leq q(x)}) (p(x) - q(x)) dx \quad (16)$$

$$= \int_x p(x) dx - \int_x q(x) dx + \int_x \mathbb{1}_{p(x) \leq q(x)} (p(x) - q(x)) dx \quad (17)$$

$$= 1 - 1 + \int_x (\mathbb{1}_{p(x) < q(x)} + \mathbb{1}_{p(x) = q(x)}) (p(x) - q(x)) dx \quad (18)$$

$$= \int_x \mathbb{1}_{p(x) < q(x)} (p(x) - q(x)) dx + \int_x \mathbb{1}_{p(x) = q(x)} (p(x) - q(x)) dx \quad (19)$$

$$= 0 + 0 = 0 \quad (20)$$

So $\int_x \mathbb{1}_{p(x) > q(x)} (p(x) - q(x)) dx = 0$ and since the term in the integral is always non-negative, $\mathbb{1}_{p(x) > q(x)} (p(x) - q(x)) = 0$ for almost all x . And $p(x) - q(x) = 0$ implies $\mathbb{1}_{p(x) > q(x)} = 0$, so $\mathbb{1}_{p(x) > q(x)} = 0$ almost everywhere. Therefore $\int_x \mathbb{1}_{p(x) > q(x)} dx = 0$ which completes the proof, given the hypothesis. \square