

AE를 활용하여 AE의 latent space의 분포를 낮고 낮은 recon loss 달성

NF를 활용하여, VAE보다 높은 성능을 보임

* Motivations.

PAE는 Linear PCA와 PCA-based data likelihood를 측정하는 확률적 해석에서 동기부여 받았다.

고정된 latent space $k(k < N)$ 에 PCA $x \in \mathbb{R}^N$ 은 orthogonal linear transform O 로 찾을 수 있다.

$$O : \mathbb{R}^K \rightarrow \mathbb{R}^N, z \mapsto Oz, OO^T = \mathbb{1}_N$$

↳ latent space의 data variance를 최대화.

↳ recon error 최소화.

↳ PCA는 analysis 하고, 각 성분은 공분산 행렬의 eigenvector로 측정.

적절한 k 는 eigenvalue가 0이 될 때까지, 큰 값이 나오는 eigenvector만 남긴다

$$\text{reconstruction error } \sigma_{\text{recon}}^2 = \sum_{i=k+1}^N \lambda_i$$

PCA의 data model은 $x = Oz + \epsilon \rightarrow$ 노이즈

↳ 큰 eigenvalue의 eigenvector로 이루어짐.

Probabilistic PCA (PPCA)의 residual은 gaussian으로 가정된다.

Implicit likelihood는

$$\ln \tilde{p}(x|z) = -\frac{1}{2} [N \ln(2\pi) + \ln \det \Sigma + (x - Oz)^T \Sigma^{-1} (x - Oz)].$$

$$\hookrightarrow \Sigma = \sigma_{\text{recon}}^2 I_N$$

↳ diagonal matrix

Prior의 경우, PPCA에선 latent가 $\mathcal{N}(0, I)$ 를 따른다고 가정

gaussian의 marginal은 analytically 계산 가능

$$\ln \tilde{p}(x) = -\frac{1}{2} [N \ln(2\pi) + \ln \det C + x^T C^{-1} x], \quad \text{with } C = O \Lambda O^T + \Sigma.$$

즉, PPCA는 recon error를 최소화하는 basis를 찾고, latent의 distribution을 prior로 model을 구성.

논문은 AE로 이 과정을 비선형화. PCA \rightarrow AE, gaussian prior \rightarrow NF

* The probabilistic AE.

- PAE training




Figure 1: Schematic diagram of the PAE (left panel) and an illustration of the sampling procedure from the PAE (right panel). The autoencoder networks are depicted as gray trapezia, the normalizing flow is represented by black arrows and the latent spaces of the autoencoder and normalizing flow are shown in red and blue, respectively.

2 stage로 동작

stage 1.

enc: f_ϕ , dec: g_θ , latent dim: k

$$\mathcal{L}_{\text{AE}} = \mathbb{E}_{p(x)} \|x - g_\theta(f_\phi(x))\|_2^2.$$

확률 모델이 아닌 AE를 확률적으로 해석하기 위해 stage 2.

stage 2.

encoding 된 latent data에 대해 density estim을 하며 $p(z)$ 근사. (NF 이용)

$$b_\gamma: \mathbb{R}^K \rightarrow \mathbb{R}^K, z \mapsto u = b_\gamma(z).$$

$$p_\gamma(z) = q(u) |\nabla_z b_\gamma(z)|.$$

$\hookrightarrow \mathcal{N}(\mathbf{0}, \mathbf{I})$ $\hookrightarrow \text{Jacobian.}$

$$\mathcal{L}_{\text{NF}} = \mathbb{E}_{\tilde{p}(z)} [-\ln p_\gamma(z)] = \mathbb{E}_{\tilde{p}(z)} \left[-\ln p(u) - \ln \left| \det \frac{\partial b_\gamma^{-1}(u)}{\partial u} \right| \right]_{u=b_\gamma(z)}.$$

\hookrightarrow latent를 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 로 mapping

$$x = g_\theta(b_\gamma^{-1}(u)).$$

AE는 확률 모델이 아니기 때문에 encoding된 latent는 delta로 볼 수 있다.

NF는 이런 delta를 복도럽게 보인

완벽한 확률 모델은 전체 x 에 대한 밀도 추정이 필요하고, posterior에 대해 density estim이 필요.

$$p_{\text{model}}(z) = \int dx p(x) p_{\text{model}}(z|x) = \mathbb{E}_{p(x)} [p_{\text{model}}(z|x)],$$

NF는 낮은 차원에 대해서는 빠르고 효율적이다.

- Comparison to VAE

VAE는 ELBO의 lower bound를 보장하지만, \mathcal{L}_{rec} 과 \mathcal{L}_{kl} 사이의 조정이 필요하다

PAE는 개념적으로 최적화.

$$\mathcal{L}_{\beta\text{-VAE}} = -\mathbb{E}_{p(x)} [\mathbb{E}_{q_{\phi}(z|x)} [\ln p_{\theta}(x|z)] - \beta D_{\text{KL}} [q_{\phi}(z|x) || p(z)]] .$$

$$\mathcal{L}_{\text{flow-VAE}} = -\mathbb{E}_{p(x)} [\mathbb{E}_{q_{\phi}(z|x)} [\ln p_{\theta}(x|z)] - D_{\text{KL}} [q_{\phi}(z|x) || p_{\gamma}(z)]] .$$

* Downstream task.

- Anomaly detection.

likelihood를 최적화하는 VAE 등은 anomaly detection이 실패할 수 있다.

하지만 PAE는 likelihood를 최적화하지 않고, recon prior를 따르한다.

∴ Anomaly detection이 유용.

$$\ln \tilde{p}(z) = -\frac{1}{2} \left[K \ln(2\pi) + \sum_i^K \ln \lambda_i + \sum_i^K z_i \lambda_i^{-1} z_i \right].$$




Figure 2: Principal component analysis of FashionMNIST and MNIST data sets and outlier detection accuracy (in-distribution: Fashion MNIST, out-of-distribution: MNIST) with equation 4 and equation 15 as a function of included number of PCA components. A higher AUROC value corresponds to a better separation between in- and out-of-distribution data.

* Experiments.